

Recuperado de:

https://www.btelligent.com/en/blog/staging-area-potential-in-comparison-to-source-system/

IMPLEMENTACIÓN DE MODELO DIMENSIONAL USANDO PENTAHO DATA INTEGRATION (PDI)

Por:

Mg. Esther Balbuena

Copyright 2019 Mg. Esther Balbuena Alarcón. Se otorga permiso para copiar, distribuir y/o modificar este documento bajo los términos de la Licencia de Documentación Libre de GNU, Versión 1.3 o cualquier otra versión posterior publicada por la Free Software Foundation. Una copia de la licencia se puede encontrar en el siguiente enlace: http://www.gnu.org/licenses/fdl-1.3.html

Fecha	Versión	Autor	Detalle del cambio
14/04/2019	0.1	Mg. Esther Balbuena	Versión Inicial.
17/09/2019	0.2	Mg. Esther Balbuena	Actualización

Para ver la traducción no oficial de la Licencia de Documentacion Libre de GNU, seguir el siguiente enlace: http://stuff.danexnow.org/gfdl es.html

IMPLEMENTACIÓN DE MODELO DIMENSIONAL

Objetivo: Implementar el modelo dimensional de un datawarehouse usando las bases de datos dimensionales y Pentaho Data Integration para los procesos ETL.

1) Requisitos previos

Tener instalado Pentaho Data Integration versión Community.
 Descarga desde:

https://community.hitachivantara.com/docs/DOC-1009931-downloads



Una vez descargado el archivo, procedemos a descomprimirlo en algún lugar apropiado (sugerido: C:\)

- b) Tener instalado MySql Server y Workbench Descargar desde el siguiente enlace: https://dev.mysql.com/downloads/mysql/
 - Instalar MySql Server y MySql Workbench para la versión de Sistema Operativo que cuente en su máquina.
- c) Configuración:
- Descargar de: https://dev.mysql.com/downloads/connector/j/
- Descomprimir el archivo zip (en mi caso uso mysql-connector-java-5.1.31.zip)
- Copiar el archivo .jar (mysql-connector-java-5.1.31.-bin.jar) y pegarlo en el folder Lib del PDI:
- PC: C:\pdi-ce-8.2.0.0-342\data-integration\lib, o la dirección donde se descomprimió PDI
- Mac: /Applications/data-integration/lib
- d) Reconocer la estructura de datos de la fuente de datos fichero book.csv

"user_code"|"user_id|"producto"|nota|texto|resaltar|subrayar|tachar|manoalzada|rectangulo|elipse|"nive" | "000007b7-a199-47a4-8288-441880f97a11"|"Usuario Usuario 55000"|55000|"ESA172025"|1|0|0|0|0|0|0|1|"Secundaria e historia. 4 ESO. Savia"|"Alumno"|"Castilla-La Mancha"

"0000c53a-899d-4051-a579-e74cfd5e4d1f"|"Usuario Usuario 55001"|55001|"ESA146820"|0|0|0|0|0|0|0|0|"Secundaria

- 2) Creación del staging area para guardar los datos desde la fuente de datos.
 - Se debe tener el servicio de MySgl arriba.
 - Abrir MySql Worbench y crear la Base de Datos stg_apellido (en mi caso stg_ebalbuena)
 - Crear la tabla f_salida que almacenará los datos que vienen de la fuente de datos fichero_book.csv

```
CREATE DATABASE IF NOT EXISTS 'stg_ebalbuena' /*!40100 DEFAULT CHARACTER SET utf8 */;
USE `stg_ebalbuena`;
-- Table structure for table `f_salida`
DROP TABLE IF EXISTS `f_salida`;
/*!40101 SET @saved cs client = @@character set client */;
/*!40101 SET character_set_client = utf8 */;
CREATE TABLE `f_salida` (
 'user code' varchar(100) NOT NULL,
'user' varchar(100) NOT NULL,
`user_id` int(11) DEFAULT NULL,
 'producto' varchar(100) DEFAULT NULL,
 'nota' int(11) DEFAULT NULL,
 `texto` int(11) DEFAULT NULL,
 'resaltar' int(11) DEFAULT NULL,
 `subrayar` int(11) DEFAULT NULL,
 `tachar` int(11) DEFAULT NULL,
 `manoalzada` int(11) DEFAULT NULL,
 `rectangulo` int(11) DEFAULT NULL,
 'elipse' int(11) DEFAULT NULL,
 'nivel' varchar(100) DEFAULT NULL,
 `curso` varchar(100) DEFAULT NULL,
 `asignatura` varchar(100) DEFAULT NULL,
 `titulo` varchar(250) DEFAULT NULL,
'rol' varchar(100) DEFAULT NULL,
 `zona` varchar(100) DEFAULT NULL
) ENGINE=InnoDB DEFAULT CHARSET=latin1 COMMENT='tabla f salida';
/*!40101 SET character_set_client = @saved_cs_client */;
/*!40103 SET TIME_ZONE=@OLD_TIME_ZONE */;
```

3) Creación de una conexión de Pentaho Data Integration y MySql.

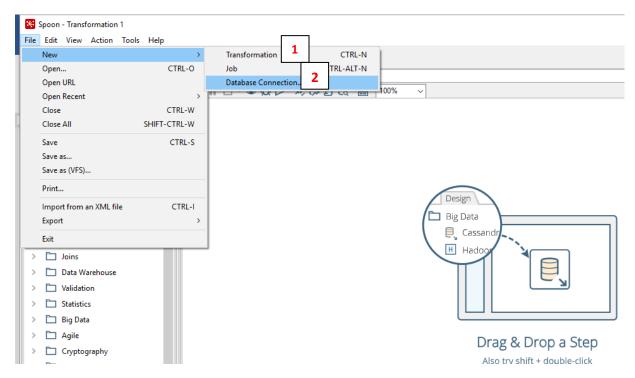
a) Iniciar Pentaho Data Integration ejecutando:

Spoon.bat	14/11/2018 17:21	Archivo por lotes	5 KB
spoon.command	14/11/2018 17:21	Archivo COMMA	2 KB
🔀 spoon.ico	14/11/2018 17:21	Icono	362 KB

b) Crear una conexión a base de datos:

1. Crear nueva transformación

2. Crear nueva conexión a base de datos



Configurar la conexión:

Parámetros:

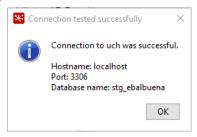
✓ Connection name: uch✓ Connection type: MySQL

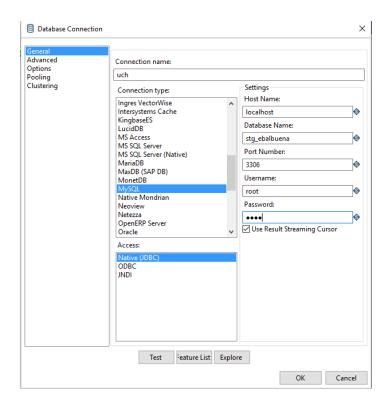
✓ Access: Native (JDBC)✓ Host name: localhost

✓ Database name: stg ebalbuena

✓ Port number: 3306✓ User name: root✓ Password: root

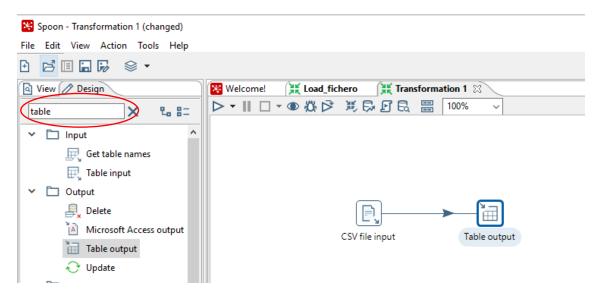
c) Presionar botón test:



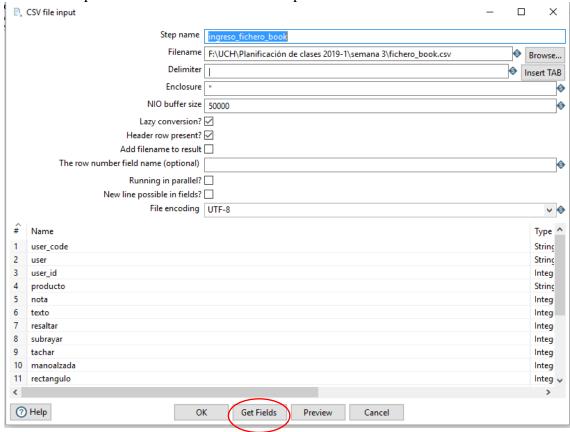


4) Cargar los datos desde la fuente de datos al staging área.

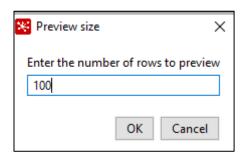
Usaremos dos pasos: CSV file input y Table output. Puede usar el buscador para hallarlos con facilidad

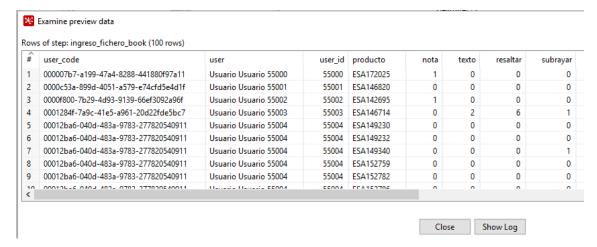


a) Configuramos el paso CSV file input. Le damos doble click al paso CVS file input y aparecerá la siguiente ventana donde completamos la dirección de la fuente de datos, es decir, la dirección de fichero_book, completamos el delimitador de campos que en este caso es | y con qué carácter están cerrados los campos. Escogemos UTF-8 como codificador de archivo. Le damos click a Get files para ver los encabezados de campos:



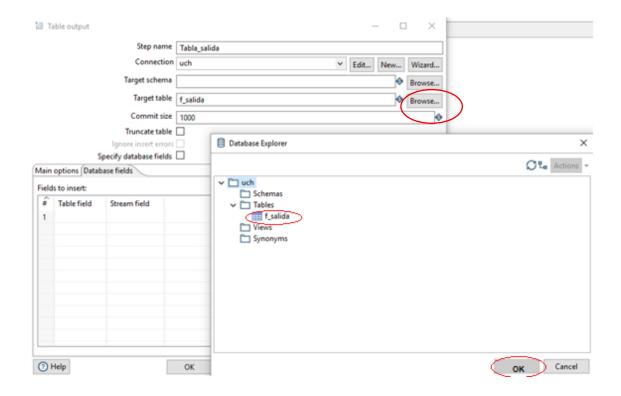
También podemos tener una vista previa de los datos presionando el botón Preview en la pantalla anterior:



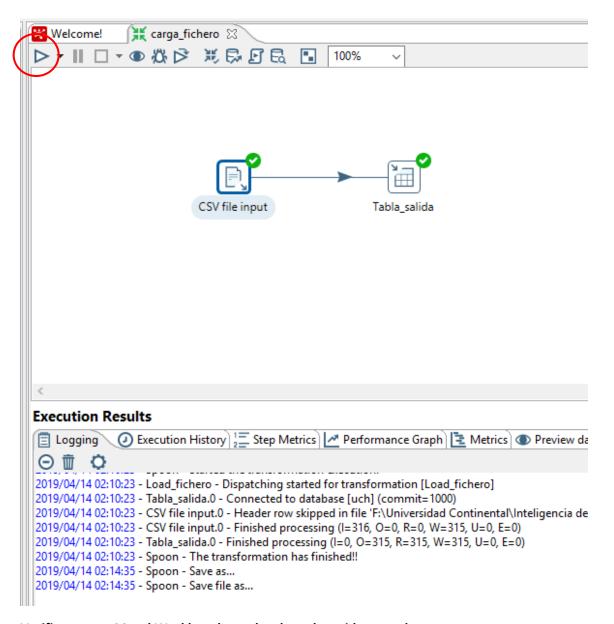


Cerramos está pantalla y le damos Ok a la pantalla emergente principal.

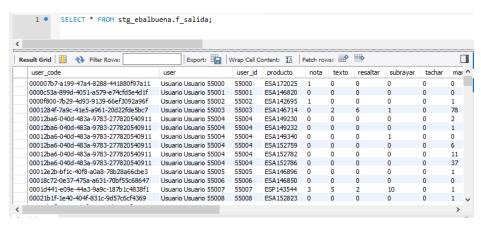
b) Configuramos el paso Table output. Le damos doble click al Table output y aparecerá la siguiente ventana donde elegiremos la **conexión uch** que se configuró en un paso anterior. El target table lo buscamos en la base datos MySql que es donde está el staging área dando click al botón Browse.



c) Ejecutamos la transformación haciendo click en RUN, nos pedirá que lo grabemos (nombre.ktr), grabe en su carpeta de trabajo. Con lo cual se habrá almacenado los datos de la fuente (fichero_book.csv) al staging área (tabla f_salida en base de datos stg_ebalbuena)



Verificamos en Mysql Workbench que los datos han sido cargados:



5) Implementación del modelamiento dimensional correspondiente al datawarehouse.

Tabla de hecho	fact_fichero
Tablas de dimensiones	dim_asignatura dim_rol dim_nivel dim_usuario dim_producto

Creamos una base de datos usando MySql WorkBench, que corresponde al datawarehouse que almacenará los datos para el análisis tomando el esquema estrella.

```
CREATE DATABASE IF NOT EXISTS `stg_ebalbuena` /*!40100 DEFAULT CHARACTER SET utf8 */;
USE `stg_ebalbuena`;
```

Script de creación de tabla dimensión (Usar este script como modelo para crear las demás tablas de dimensiones.

```
-- Table structure for table `dim_asignatura`

DROP TABLE IF EXISTS `dim_asignatura`;

CREATE TABLE `dim_asignatura` (
   `id` int(11) NOT NULL AUTO_INCREMENT,
   `desc` varchar(50) NOT NULL DEFAULT '0',
   PRIMARY KEY (`id`)

) ENGINE=InnoDB AUTO_INCREMENT=604 DEFAULT CHARSET=utf8;
```

Script de creación de la tabla de hecho: fact_fichero:

```
CREATE TABLE `fact_fichero` (
    `id` int(11) NOT NULL AUTO_INCREMENT,
    `id_asignatura` int(11) NOT NULL,
    `id_nivel` int(11) NOT NULL,
    `id_rol` int(11) NOT NULL,
    `id_usuario` int(11) NOT NULL,
    `id_producto` int(11) NOT NULL,
    `c_notas` int(11) NOT NULL DEFAULT '0',
    `c_texto_libre` int(11) NOT NULL DEFAULT '0',
    `c_resaltar_texto` int(11) NOT NULL DEFAULT '0',
    `c_subrayar_texto` int(11) NOT NULL DEFAULT '0',
    `c_tachar_texto` int(11) NOT NULL DEFAULT '0',
    `c_mano_alzada` int(11) NOT NULL DEFAULT '0',
    `c_rectangulo` int(11) NOT NULL DEFAULT '0',
    `c_rectangulo` int(11) NOT NULL DEFAULT '0',
```

```
PRIMARY KEY ('id'),

UNIQUE KEY 'id_unique' ('id_usuario', 'id_producto'),

KEY 'id_asignatura' ('id_asignatura'),

KEY 'id_nivel' ('id_nivel'),

KEY 'id_rol' ('id_rol'),

KEY 'id_producto' ('id_producto'),

KEY 'IDX' ('id_usuario', 'id_producto')

) ENGINE=InnoDB AUTO_INCREMENT=836001 DEFAULT CHARSET=utf8;
```

Verificamos que se haya creado la estructura deseada:

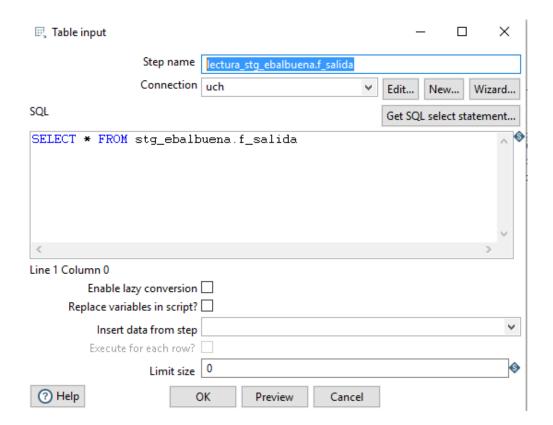


- 6) Carga de datos desde el staging área (stg_ebalbuena.f_salida) a nuestro Datawarehouse (olap_ebalbuena)
- a) Carga de datos a las tablas dimensiones. Abrimos una nueva transformación y realizaremos los procesos ETL para cada dimensión usando los siguientes pasos:

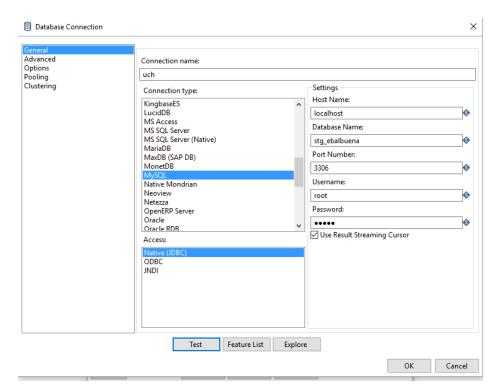


Configuramos cada paso, lo cual debe ser realizado para cada dimensión.

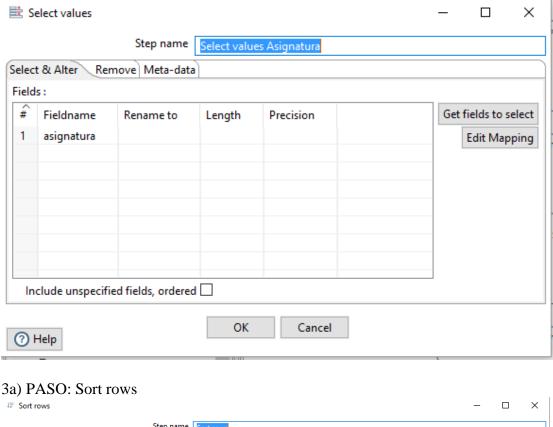
1a) PASO: lectura_stg_ebalbuena.f_salida

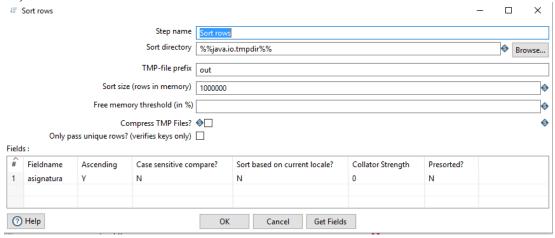


Configuramos la conexión uch que apunta al staging área.

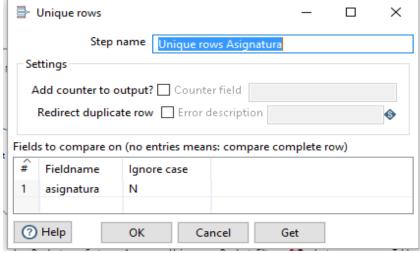


2a) PASO: Select values Asignatura.

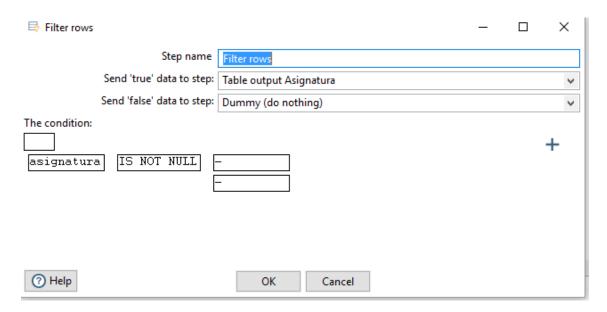




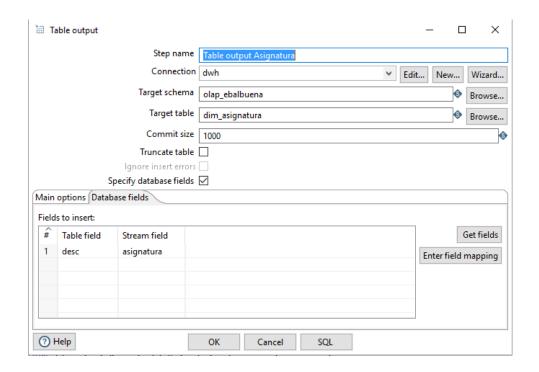
4a) PASO: Unique rows Asignatura

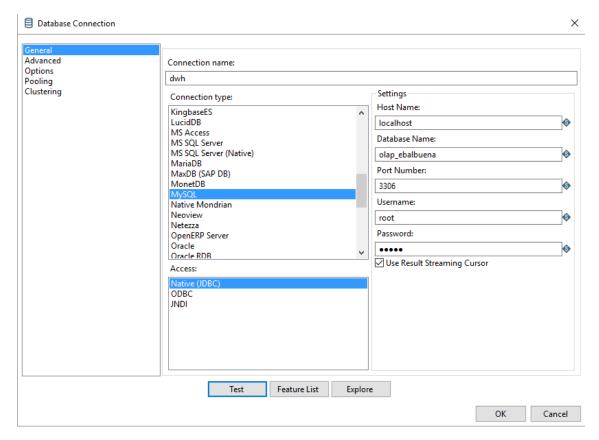


5a) Paso: Filter rows

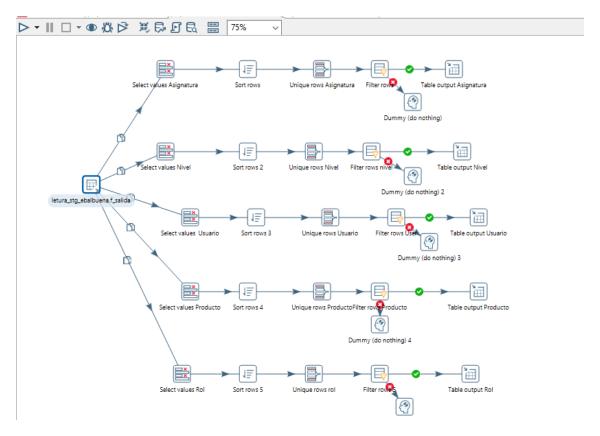


6a) PASO: Table output Asignatura con la conexión dwh a olap_ebalbuena

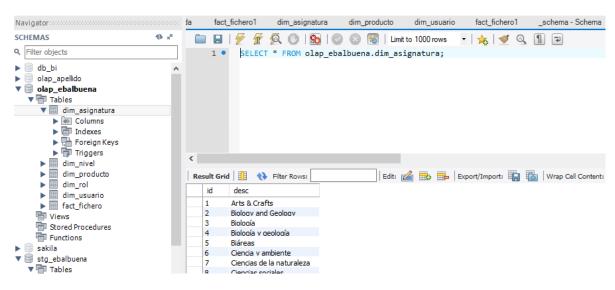




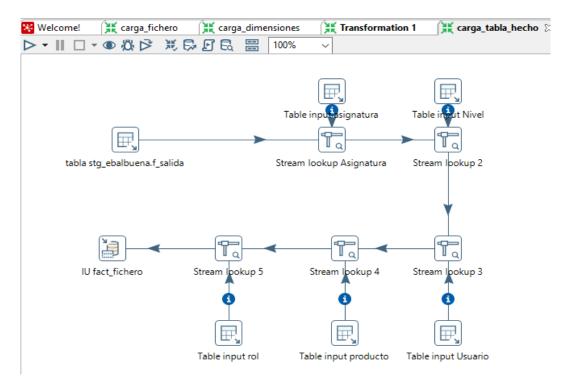
Usar los mismos pasos de 2a a 6a para cada dimensión. El modelo final debe tener todas las dimensiones que se definieron en el modelo:



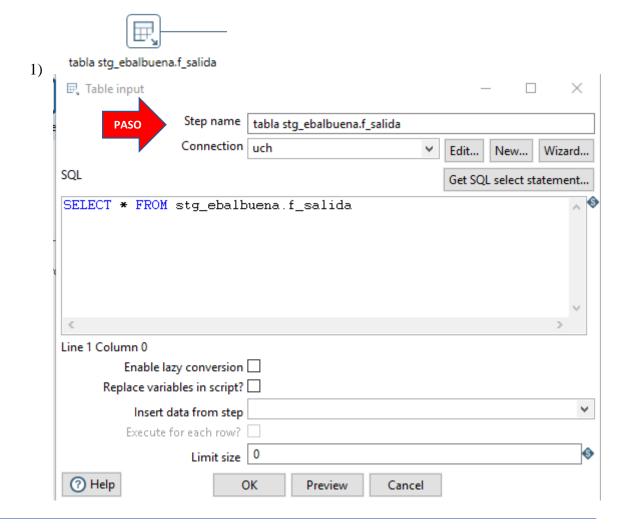
Corremos la actual transformación y luego verificamos que los datos se hayan cargado en nuestra base de datos.



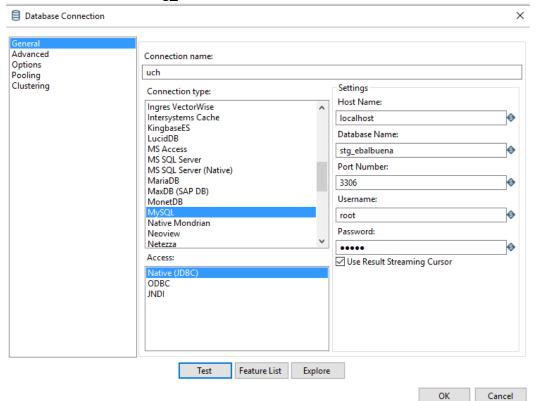
b) Carga de datos a la tabla de hechos: fact_fichero. Abrimos una nueva transformación y realizaremos los procesos ETL para cargar la tabla de hechos usando los siguientes pasos:



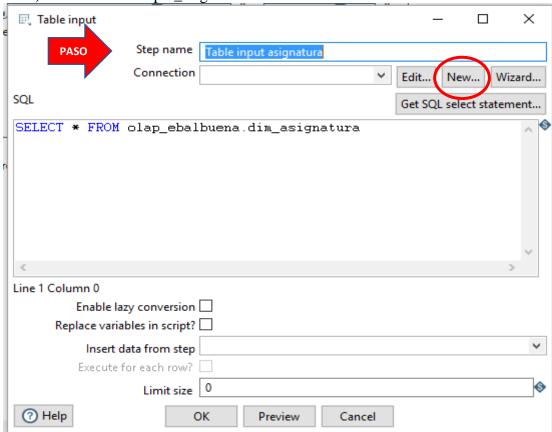
Configuración de cada paso:

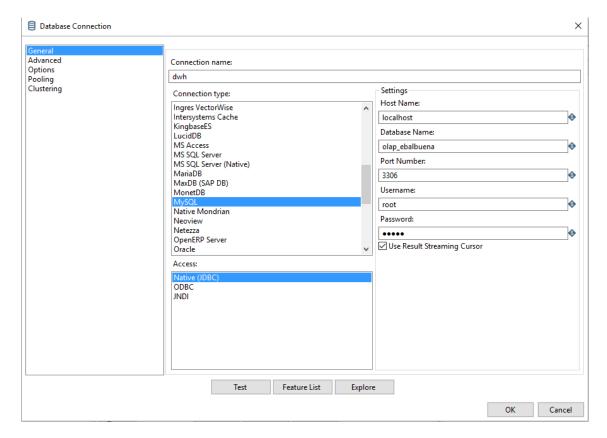


Usamos la conexión a stg_ebalbuena



2) PASO: Table input_asignatura

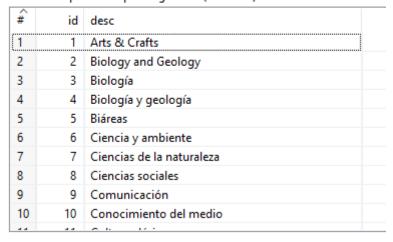




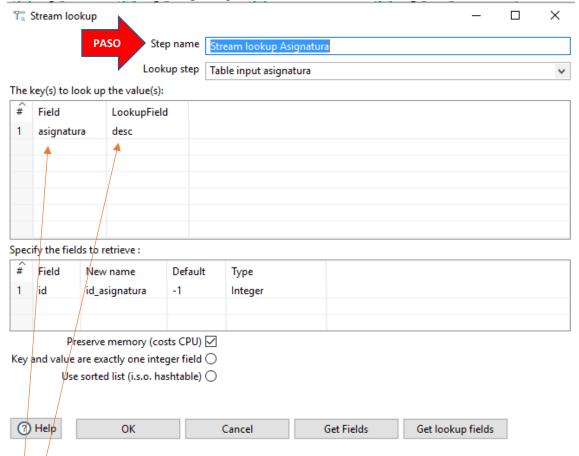
Examinamos la data con una vista previa:

Examine preview data

Rows of step: Table input asignatura (100 rows)



3) PASO: Stream lookup Asignatura



asignatura, es el campo que viene de la tabla f_salida (staging área)

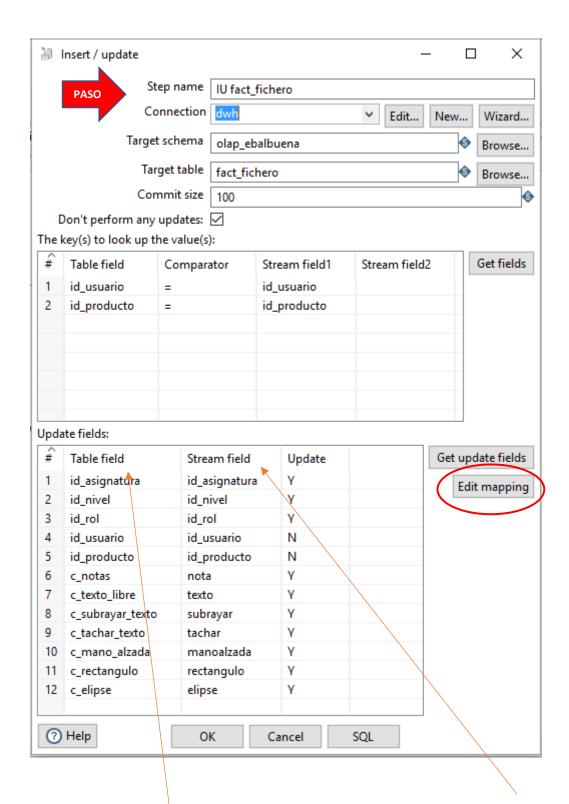
desc, es el campo de la tabla de hecho fact_fichero donde se guardará ese dato.

- 4) Los pasos 2 y 3 deben configurarse de manera similar para cada dimensión.
- 5) PASO:

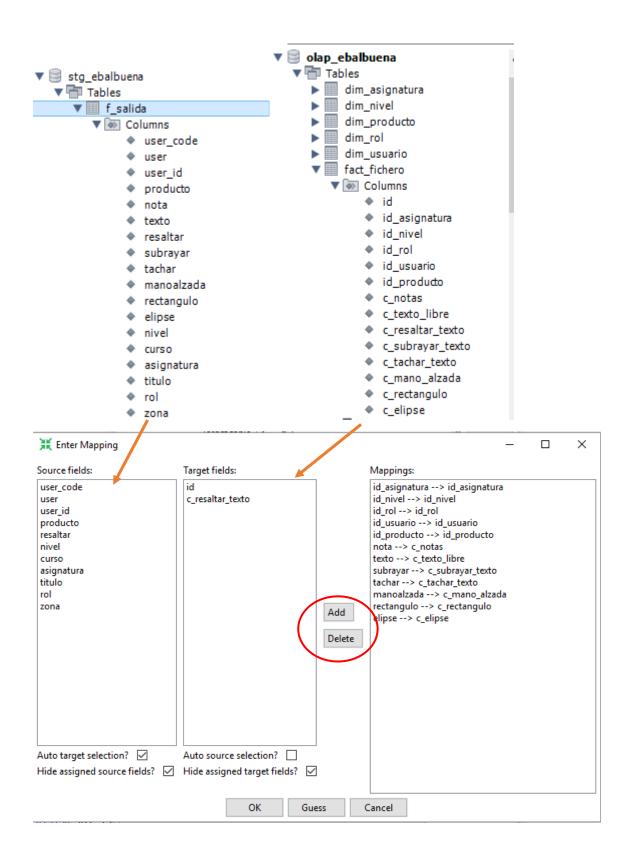


IU fact_fichero

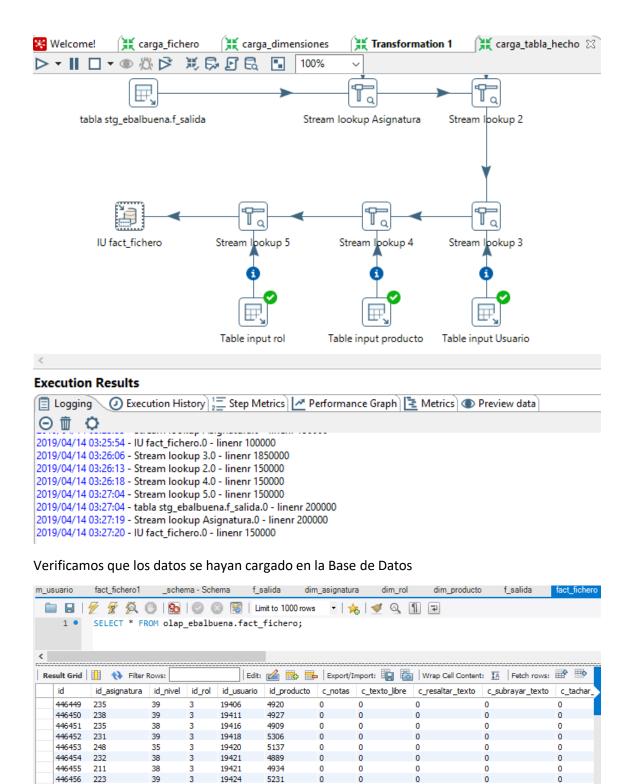
En este paso se realiza la carga de datos a la tabla de hechos en el Datawarehouse que está dado la tabla olap_ebalbuena.fact_fichero.



Usamos la opción Edit mapping para relacionar los campos que vienen del **staging** : **f_salida** con los campos de **la tabla de hechos** olap_ebalbuena.fact_fichero.



Corremos la transformación y veremos en la zona de Logging como avanza la ejecución hasta llegar al último paso.



¡Muy bien! Ya tenemos nuestra almacén con los datos cargados. Ya estamos listos para explotar los datos.

n

n